

Nâng cao hiệu suất dự đoán các bệnh từ hình ảnh X-quang ngực sử dụng các mô hình CNN và giải thuật tiền xử lý

Hoang-Quy Nguyen¹, Minh-Van Nguyen-Truong¹, Bao-Khanh Truong-Phuoc¹,
and Minh-Tien Nguyen¹

Khoa Khoa Học và Kỹ Thuật Thông Tin, Trường Đại Học Công Nghệ Thông Tin,
Đại Học Quốc Gia thành phố Hồ Chí Minh, Việt Nam
20521815@gm.uit.edu.vn, 20522146@gm.uit.edu.vn, 20520579@gm.uit.edu.vn,
20522010@gm.uit.edu.vn

Tóm tắt nội dung Trong bối cảnh y tế toàn cầu, hình ảnh X-quang ngực đã trở thành một công cụ quan trọng trong việc chẩn đoán và đánh giá tình trạng bệnh phổi. Trong nghiên cứu này, chúng tôi tập trung vào nâng cao hiệu suất dự đoán các loại bệnh từ hình ảnh X-quang ngực sử dụng các mô hình Convolutional Neural Network (CNN) và áp dụng các thuật toán tiền xử lý để cải thiện chất lượng hình ảnh. Chúng tôi sử dụng bộ dữ liệu Chest-Xray14 (2017) và CheXpert, chứa hàng nghìn hình ảnh X-quang ngực, bao gồm các trường hợp bệnh phổi khác nhau. Để tăng cường chất lượng hình ảnh, chúng tôi áp dụng các giải thuật tiền xử lý, bao gồm Background Removal (loại bỏ phần nền), Noise Removal (loại bỏ nhiễu), Diaphragm Removal (loại bỏ màng phổi) và Contrast Enrichment (tăng cường độ tương phản). Các thuật toán này đã giúp làm sạch hình ảnh, loại bỏ nhiễu và tăng cường các chi tiết quan trọng trong hình ảnh X-quang ngực. Tiếp theo, chúng tôi xây dựng một tập hợp các mô hình CNN, bao gồm Dense121, VGG19, EfficientNetV2 và ConvNeXt. Kết quả thử nghiệm trên hai tập dữ liệu đã cho thấy phương pháp tiền xử lý của chúng tôi giúp tăng hiệu suất của mô hình. Đồng thời, chúng tôi thấy mô hình ConvNeXt đạt hiệu suất tốt nhất trong việc dự đoán các loại bệnh trên. Những kết quả này có ý nghĩa quan trọng và là công cụ hỗ trợ đáng tin cậy cho các chuyên gia y tế, đặc biệt là các chuyên gia X-quang. Đề tài này đóng góp vào việc cải thiện khả năng dự đoán và giảm thiểu sai sót trong quá trình chẩn đoán bệnh phổi, mang lại lợi ích lớn cho việc chăm sóc sức khỏe cộng đồng.

Keywords: hình ảnh X-quang ngực · mạng neural tích chập · tiền xử lý hình ảnh · phân loại hình ảnh · Chest-Xray14 (2017) · CheXpert.

1 Giới thiệu

Bài toán chuẩn đoán các loại bệnh từ hình ảnh X-quang ngực đóng vai trò quan trọng trong lĩnh vực y tế. Sự phát triển nhanh chóng của công nghệ và sự tiến bộ trong lĩnh vực trí tuệ nhân tạo đã tạo ra những tiềm năng lớn để áp dụng

các phương pháp học sâu vào việc xử lý hình ảnh y tế và hỗ trợ quyết định chẩn đoán.

Để đạt được hiệu suất tốt trong việc phân loại bệnh từ hình ảnh X-quang ngực, quy trình chuẩn đoán thường bao gồm các bước tiền xử lý và mô hình hóa dữ liệu. Bước tiền xử lý hình ảnh có thể bao gồm loại bỏ nền, loại bỏ nhiễu, tăng cường độ tương phản và phân đoạn vùng quan tâm (ROIs) để tập trung vào các khu vực quan trọng trong ảnh X-quang ngực. Những bước này giúp cải thiện chất lượng hình ảnh và loại bỏ những yếu tố không cần thiết, từ đó tăng cường khả năng phân loại và phát hiện bệnh.

Mạng nơ-ron tích chập (CNN) là một công cụ mạnh mẽ được sử dụng rộng rãi trong các ứng dụng xử lý hình ảnh, bao gồm cả phân loại bệnh từ hình ảnh X-quang ngực. CNN có khả năng học các đặc trưng trừu tượng từ dữ liệu huấn luyện và phát hiện các mẫu quan trọng trong ảnh. Các mô hình CNN như DenseNet, ResNet, và VGG19 đã được áp dụng thành công trong việc phân loại các loại bệnh phổi từ hình ảnh X-quang ngực.

Dù cho mô hình có đạt được độ chính xác cao trong việc phân loại bệnh từ hình ảnh X-quang ngực, sự chẩn đoán cuối cùng vẫn phải dựa vào sự đánh giá của các chuyên gia y tế. Mô hình chỉ có thể cung cấp thông tin tham khảo và hỗ trợ quyết định, nhưng quyết định chẩn đoán cuối cùng thuộc về bác sĩ và nhóm y tế chuyên môn.

Tóm lại, bài toán chuẩn đoán các loại bệnh từ hình ảnh X-quang ngực đã mang lại nhiều tiềm năng trong việc ứng dụng trí tuệ nhân tạo và học máy trong lĩnh vực y tế. Tuy nhiên, để đạt được kết quả chẩn đoán chính xác và đáng tin cậy, cần có sự kết hợp giữa mô hình học máy và sự chuyên môn của các bác sĩ và nhóm y tế. Sự phát triển trong lĩnh vực này sẽ tiếp tục mở ra những cơ hội mới trong việc nâng cao chất lượng chăm sóc sức khỏe và giúp đỡ hàng triệu người trên toàn thế giới.

Do đó, trong đề tài này, chúng tôi sẽ xây dựng một mô hình có thể nhận diện các bệnh về phổi từ ảnh X-quang ngực, một hình ảnh có thể có nhiều bệnh khác nhau. Để mô hình hoạt động tốt, chúng tôi sử dụng một số thuật toán tiền xử lý hình ảnh trên hình ảnh X-quang ngực. Bước đầu tiên là loại bỏ background và xóa nhiễu trên ảnh. Tiếp theo, chúng tôi sử dụng giải thuật CLAHE để tăng cường độ tương phản cho ảnh. Cuối cùng, chúng tôi sẽ xóa bỏ vùng cơ hoành (diaphragm) trên ảnh. Chúng tôi sẽ fine-tune các mô hình CNN trên dữ liệu đã tiền xử lý, đồng thời sẽ thực hiện so sánh dữ liệu chưa và đã tiền xử lý để thấy được tầm quan trọng của giai đoạn này.

2 Bộ dữ liệu

Deep learning đòi hỏi một lượng lớn dữ liệu được gán nhãn. Sự số hóa của quy trình làm việc trong lĩnh vực chẩn đoán hình ảnh y khoa cho phép các cơ sở y tế thu thập và phân loại hình ảnh kỹ thuật số. Ngoài ra, sự tiến bộ trong các thuật toán xử lý ngôn ngữ tự nhiên (NLP) giúp các báo cáo hình ảnh y khoa hiện nay có thể được trích xuất tự động nhãn quan tâm cho mỗi hình ảnh. Những yếu tố này đã tạo điều kiện cho việc xây dựng và phát hành nhiều bộ dữ liệu CXR

được gán nhãn lớn trong những năm gần đây. Các phương pháp gán nhãn khác bao gồm việc đính kèm toàn bộ báo cáo hình ảnh y khoa và/hoặc nhãn được tạo ra bằng các cách khác nhau, như xem xét hình ảnh bởi các chuyên gia y khoa, xem xét báo cáo y khoa hoặc kết quả thử nghiệm trong phòng thí nghiệm.

Trong phần này, chúng tôi sẽ trình bày chi tiết từng bộ dữ liệu được nhóm chúng tôi sử dụng. Thông tin chi tiết của bộ dữ liệu được trình bày ở Bảng 1.

| | Patients (P) Studies (S) Images (I) | View Positions | Annotations | | | Image Format | Label Method | Gold Standard Data |
|------------------|---|--------------------------------|-------------|---------|-------------|--------------|--------------|--------------------|
| | | | Types | Labels | Studies | | | |
| ChestX-ray14 (C) | P: 31K I: 112K | PA: 67K AP: 45K | CL BB | 14 8 | 112K 983 | PNG | RP RI | 984 |
| CheXpert | P: 65K S: 188K I: 224K | PA: 29K AP: 162K LL: 32K | CL | 14 | 224 | JPEG | RCI RP | 235 |

Bảng 1. Thông tin về bộ dữ liệu. Các giá trị lớn hơn 10,000 được làm tròn. **Label Method:** RP=Report Pairing, RI=Radiologist Interpretation, RCI=Radiologist Cohort agreement on Chest X-Rays. **Annotation Types:** BB=Bounding Box, CL=Classification. **Gold Standard Data:** số lượng nhãn được gán bằng phương pháp khác với RP

2.1 Chest-Xray14

Bộ dữ liệu ChestX-ray14 (C) bao gồm 112.120 hình ảnh CXR từ 30.805 bệnh nhân. Các hình ảnh CXR này được thu thập tại Viện Quốc gia Y tế (Hoa Kỳ). Các hình ảnh được xử lý dưới dạng hình ảnh xám 8-bit với độ phân giải 1024×1024 pixel. Bộ dữ liệu này được gán nhãn tự động từ các báo cáo hình ảnh y khoa.

2.2 CheXpert

Bộ dữ liệu CheXpert (X) bao gồm 224.316 hình ảnh CXR từ 65.240 bệnh nhân. Các hình ảnh CXR này được thu thập tại Bệnh viện Stanford từ tháng 10 năm 2002 đến tháng 7 năm 2017. Các hình ảnh được thu nhập dưới dạng hình ảnh xám 8-bit với độ phân giải ban đầu. Bộ dữ liệu này đã được gán nhãn tự động từ các báo cáo hình ảnh y khoa bằng cách sử dụng một công cụ gán nhãn dựa trên quy tắc.


3 Phương pháp thực hiện

3.1 Tiền xử lý

Background Removal Xóa background là một kỹ thuật thường xuyên được sử dụng trong xử lý ảnh. Xóa background giúp loại bỏ các phần không cần thiết và làm cho đối tượng chính được nổi bật hơn.

Trong tác vụ xử lý ảnh X-quang ngực, các bức ảnh được chụp với background cố định ở phía sau (màn đen). Do đó, việc xóa bỏ background giúp mô hình tập trung vào vùng cần quan sát.

Trong báo cáo này, nhóm sẽ xóa vùng background đen dư thừa phía sau ảnh. Kết quả được thể hiện ở hình 1. Ảnh ban đầu là ảnh gốc trong bộ dữ liệu, ảnh thứ 2 là sau khi xóa background đen ở trên và dưới ảnh.




Hình 1. Ảnh trước và sau khi xóa background

Noise Removal Nhiễu thường xuất hiện trong ảnh kỹ thuật số tại bước thu nhập, mã hóa, xử lý ảnh. Noise Removal là quá trình loại bỏ hoặc giảm nhiễu từ hình ảnh. Các thuật toán loại bỏ nhiễu giúp giảm hoặc loại bỏ nhiễu bằng cách làm mịn toàn bộ hình ảnh.

Đối với ảnh X-quang ngực, nhiễu “tiêu” thường xuất hiện khá nhiều, điều này gây khó khăn cho tác vụ dự đoán của mô hình. Do đó nhóm sẽ thực hiện giảm nhiễu bằng bộ lọc Bilateral.


Bộ lọc Bilateral là bộ lọc không tuyến tính và có hiệu quả cao trong việc loại bỏ nhiễu, đồng thời các chi tiết trên ảnh được bảo toàn. Bộ lọc này thay thế giá trị của từng pixel bằng trọng số giá trị trung bình của các pixel lân cận, trọng số giá trị trung bình được tính dựa trên phân phối Gaussian.



Hình 2. Ảnh trước và sau khi giảm nhiễu

Diaphragm Removal Bộ dữ liệu được nhóm sử dụng chứa các ảnh X-quang được chụp theo trước-sau, do đó phần dưới cùng của hình ảnh bao gồm vùng cơ hoành với các pixel sáng có thể có gây ảnh hưởng xấu đến việc dự đoán các bệnh ở vùng phổi của mô hình. Do đó, nhóm sử dụng một thuật toán tiền xử lý để xác định và loại bỏ vùng cơ hoành trên ảnh.

Cụ thể, thuật toán này sẽ tìm giá trị pixel lớn nhất (sáng nhất - V_{max}) và pixel nhỏ nhất (tối nhất - V_{min}) trên ảnh, sau đó sử dụng ngưỡng $T = V_{min} + 0.9 * (V_{max} - V_{min})$, để phân đoạn ảnh gốc thành một ảnh nhị phân. Tiếp theo, các phép morphology (dilate, erosion, ...) được áp dụng để phát hiện và làm mịn các phân đoạn này. Với tất cả các phân đoạn được phát hiện, vùng có diện tích lớn nhất trong ảnh sẽ được chọn và xóa khỏi ảnh.




Hình 3. Ảnh trước và sau khi xóa vùng cơ hoành

Contrast Enrichment Các thuật toán tăng cường độ tương phản đã phát triển trong vài thập kỷ qua để đáp ứng sự cần thiết. Có hai mục tiêu chính trong việc nâng cao độ tương phản của hình ảnh, đầu tiên là tăng cường khả năng biểu diễn của hình ảnh; thứ hai là hỗ trợ hoặc tăng hiệu suất của các tác vụ như: phân tích hình ảnh, phát hiện đối tượng và phân đoạn hình ảnh, ...

Hầu hết các kỹ thuật tăng cường độ tương phản đều dựa trên các biểu đồ màu, có thể được áp dụng trên toàn ảnh hoặc 1 cục bộ (vùng nhỏ). Contrast Limited Adaptive Histogram Equalization (CLAHE) là một phương pháp mới giúp khắc phục những hạn chế của các phương pháp trước bằng cách tăng cường tương phản cục bộ. Đây là một phương pháp cân bằng hình ảnh thường được sử dụng để cải thiện độ tương phản của các hình ảnh y tế có độ tương phản thấp, là một biến thể của Adaptive histogram equalization (AHE) nhằm ngăn hiện tượng khuếch đại quá mức độ tương phản.

Hình ảnh X-quang ngực có thể có độ tương phản hoặc độ sáng khác nhau do sự khác biệt về kích thước cơ thể bệnh nhân hoặc sự thay đổi của liều lượng tia X. Để cân bằng lại độ tương phản, nhóm áp dụng phương pháp CLAHE để chuẩn hóa hình ảnh. Do đó, việc áp dụng CLAHE giúp điều chỉnh độ tương phản giữa các pixel và có thể làm nổi bật các đặc điểm và vùng ở phổi liên quan đến các bệnh khác nhau.




Hình 4. Ảnh trước và sau khi tăng độ tương phản

3.2 Mô hình

VGG19 Đây là một phiên bản cải tiến của mạng VGG16, gồm 19 lớp với 16 lớp tích chập và 3 lớp 'fully connected' để phân loại 1000 nhãn của hình ảnh. VGG19 được huấn luyện trên bộ dữ liệu ImageNet chứa một triệu hình ảnh thuộc 1000 nhãn khác nhau. Đây là một phương pháp rất phổ biến để phân loại hình ảnh do sử dụng nhiều bộ lọc 3x3 trong mỗi lớp tích chập.

Kiến trúc của VGG19 được thể hiện ở hình 5. Điều này cho thấy 16 lớp tích chập được sử dụng để trích xuất đặc trưng và 3 lớp tiếp theo dùng để phân loại.

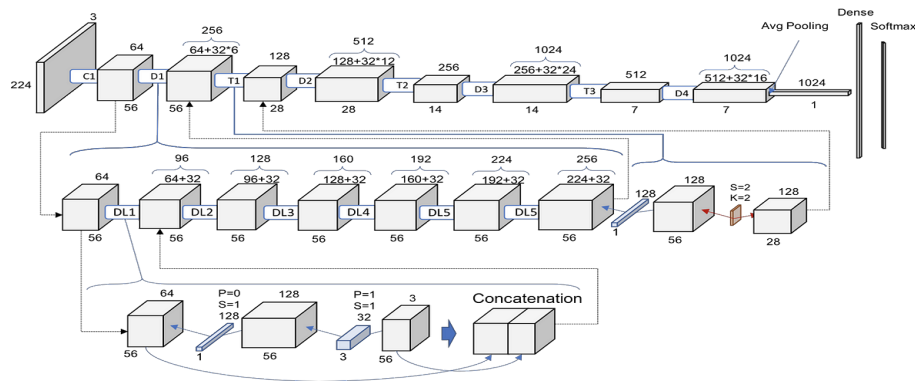
Một hình ảnh có kích thước 224×224 sẽ là đầu vào mô hình này và mô hình xuất ra nhãn tương ứng trong hình ảnh.



Hình 5. Kiến trúc mạng VGG19

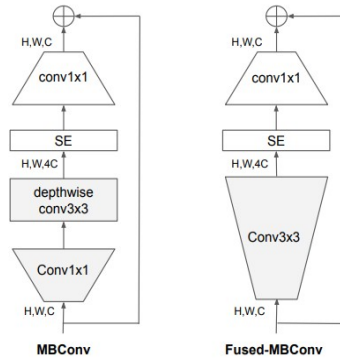
DenseNet Trong mạng CNN truyền thống, mỗi lớp sẽ nhận đầu vào từ lớp convolution trước đó và trả về kết quả đầu ra là một ma trận biểu diễn đặc trưng để làm đầu vào cho lớp tiếp theo. Tuy nhiên, sự gia tăng đáng kể số lớp của mạng CNN có thể dẫn tới hiện tượng "vanishing gradient".

Do đó, mạng DenseNet giải quyết vấn đề này bằng cách sửa đổi kiến trúc mạng CNN truyền thống và làm đơn giản hóa số kết nối giữa các lớp. Trong kiến trúc DenseNet, mỗi lớp được kết nối trực tiếp với mọi lớp khác, do đó mạng này còn có tên là Densely Connected Convolutional Network. Kiến trúc tổng quan về mạng DenseNet được mô tả ở hình 6



Hình 6. Kiến trúc mạng DenseNet

EfficientNetV2 Đây là một phiên bản cải tiến của EfficientNetV1 nhằm mục đích tăng tốc quá trình training và nâng cao độ hiệu quả của các tham số. Tốc độ huấn luyện nhanh nhất đạt được khi sử dụng cả hai convolutional block mới là MBConv và Fused-MBConv.



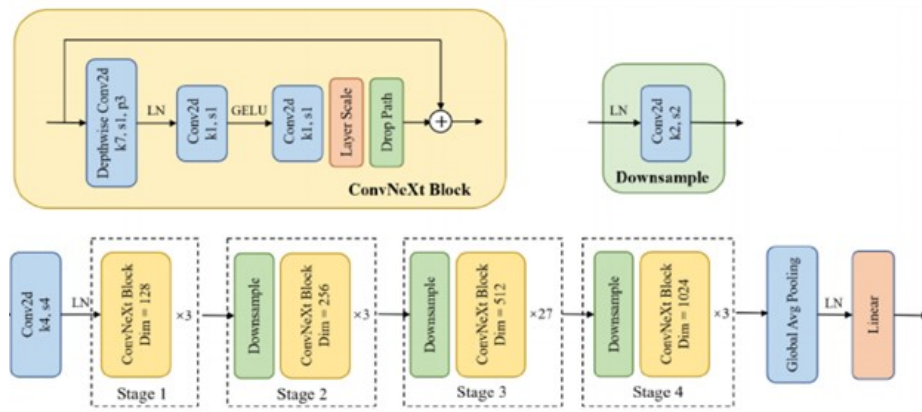
Hình 7. Khối MBConv và khối Fused-MBConv

MBConv là cấu trúc cơ bản của MobileNetV2. Khác biệt về cấu trúc của MBConv và Fused-MBConv nằm ở hai block đầu tiên. Trong khi MBConv sử dụng depthwise convolution (3x3) theo sau bởi 1x1 convolution layer, thì Fused-MBConv thay thế hai block đầu với một 3x3 convolutional layer.

Các Fused MBConv layer có thể giúp huấn luyện nhanh hơn chỉ với một lượng nhỏ tham số tăng lên, nhưng nếu nhiều block này được sử dụng, nó có thể làm chậm quá trình huấn luyện với nhiều tham số được thêm vào. Để khắc phục vấn đề này, các tác giả đã sử dụng cả MBConv và Fused-MBConv trong neural architecture search, tự động quyết định sự kết hợp tốt nhất của các block này để có hiệu suất và tốc độ tốt nhất.

ConvNeXt Đây là một mô hình SOTA đã đạt được kết quả tốt nhất là 87.8% trên bộ ImageNet. Mô hình được xây dựng hoàn toàn từ mạng CNN truyền thống, kết quả thu được tốt hơn Transformer về độ chính xác và khả năng mở rộng trong khi vẫn duy trì tính đơn giản và hiệu quả của mạng CNN.

Về kiến trúc mạng, ConvNeXt phát triển từ mạng ResNet ban đầu và từng bước cải thiện mô hình bằng cách mượn thiết kế của Swin Transformer. Hình 8 thể hiện 4 giai đoạn của ConvNeXt. Tỷ lệ mỗi block trong mỗi giai đoạn là 1:1:9:1. Mạng CNN truyền thống thường sử dụng Batch Norm và activation là ReLu, trong khi đó ConvNeXt sử dụng Layer Norm và activation là GeLu.



Hình 8. Kiến trúc tổng quan mô hình ConvNeXt

4 Kết quả thực nghiệm

Chúng tôi áp dụng transfer learning vào 4 mô hình trên và huấn luyện lại trên 2 bộ dữ liệu Chext Xray-14 và CheXpert. Chúng tôi không huấn luyện 10% lớp tích chập đầu tiên vì lớp này đã phát hiện các mẫu cơ bản và không cần huấn luyện lại. Các lớp tích chập còn lại được huấn luyện để tìm hiểu các khuôn mẫu cụ thể cho ảnh X-quang. Chúng tôi chọn ngẫu nhiên có trọng số 40,000 mẫu trên cả 2 bộ dữ liệu. Chúng tôi chọn hàm kích hoạt là Adam với tốc độ học là 0.0001, số lượng batch size là 16 và số lượng epoch là 3.

4.1 Độ đo đánh giá

Để đánh giá hiệu suất của mô hình, chúng tôi sử dụng độ đo đánh giá là AUC. AUC là từ viết tắt của “Area Under the ROC Curve”, thuật toán này có thể tính diện tích bên dưới đường cong ROC. AUC cung cấp độ đo đánh giá trên tất cả các ngưỡng phân loại có thể, có khoảng giá trị là $[0,1]$.

4.2 Sự ảnh hưởng của tiền xử lý

Kết quả thực nghiệm của chúng tôi được thể hiện ở bảng 3. Bằng cách áp dụng các kỹ thuật mới, mô hình ConvNeXt đã đạt được kết quả tốt nhất trên cả 2 bộ dữ liệu, AUC với dữ liệu tiền xử lý lần lượt là 75.60 với bộ Chest X-ray14 và 73.84 với bộ CheXpert. Ngược lại, mô hình Dense121 có kết quả khá tệ trên bộ Chest Xray-14, AUC chỉ đạt được 0.55. Trong khi đó, mô hình VGG19 có kết quả thấp nhất trên bộ CheXpert. Nguyên nhân có thể là do mô hình không khái quát hóa được thông tin, số lượng mẫu dữ liệu huấn luyện được chúng tôi sử dụng còn khá ít (chỉ chiếm khoảng 20%).

Do đó, bằng cách áp dụng các phương pháp tiền xử lý, kết quả mô hình đã tăng lên đáng kể.

| | Chest X-ray14 | | CheXpert | |
|----------------|-----------------------|---------------|-----------------------|---------------|
| | Without Preprocessing | Preprocessing | Without Preprocessing | Preprocessing |
| Dense121 | 0.49 | 0.55 | 65.16 | 68.39 |
| VGG19 | 62.91 | 64.50 | 63.59 | 60.98 |
| EfficientNetV2 | 68.81 | 69.21 | 66.45 | 68.64 |
| ConvNeXt | 75.60 | 77.22 | 68.21 | 73.84 |

Bảng 2. So sánh kết quả trong việc tiền xử lý giữa các mô hình trên 2 bộ dữ liệu

Kết quả chi tiết độ đo AUC của mô hình ConvNeXt trên cả 2 bộ dữ liệu được thể hiện ở bảng 3. Nhìn chung, kết quả của mô hình ConvNeXt trên cả 2 bộ dữ liệu khá tương đồng nhau. Nhân Cardiomegaly có AUC cao nhất trên cả 2 bộ dữ liệu: 0.87 trên bộ Chest Xray-14 và 0.86 trên bộ CheXpert. Ngược lại, nhân Pneumonia có AUC khá thấp, AUC trên 2 bộ dữ liệu lần lượt là 0.61 và 0.66.

| | Chest Xray-14 | CheXpert |
|-------------------------|---------------|----------|
| Airspace Opacity (AO) | - | 0.64 |
| Atelectasis (A) | 0.75 | 0.67 |
| Cardiomegaly (Cd) | 0.87 | 0.86 |
| Consolidation (Co) | 0.74 | 0.69 |
| Edema (Ed) | 0.82 | 0.79 |
| Effusion (Ef) | 0.85 | - |
| Emphysema (Em) | - | - |
| Enlarged Card (EC) | - | 0.69 |
| Fibrosis | - | - |
| Fracture (Fr) | - | 0.72 |
| Hernia (H) | 0.83 | - |
| Infiltration (In) | 0.71 | - |
| Lung Lesion (LL) | - | 0.84 |
| Mas (M) | 0.76 | - |
| Nodule (N) | 0.73 | - |
| No Finding (NF) | - | - |
| Pleural Thickening (PT) | 0.80 | 0.85 |
| Pleural Other (PO) | - | 0.82 |
| Pneumonia (Pa) | 0.61 | 0.66 |
| Pneumothorax (Px) | 0.73 | 0.88 |
| Support Devices (SD) | - | 0.81 |

Bảng 3. So sánh AUC ở mô hình ConvNeXt trên cả 2 bộ dữ liệu

5 Kết luận

Trong nghiên cứu này, chúng tôi tập trung vào việc nâng cao hiệu suất của các mô hình dự đoán các loại bệnh bằng cách sử dụng các giải thuật tiền xử lý.

Bộ dữ liệu chúng tôi sử dụng trong nghiên cứu bao gồm Chest-Xray14 (2017) và CheXpert. Trước khi đưa dữ liệu vào mô hình huấn luyện, chúng tôi đã áp dụng các giải thuật tiền xử lý để cải thiện chất lượng hình ảnh. Điều này đặc biệt hữu ích trong việc phân biệt các biểu hiện và dấu hiệu nhỏ có thể chỉ ra các loại bệnh khác nhau trong hình ảnh X quang ngực.

Sau khi áp dụng các giải thuật tiền xử lý, chúng tôi sử dụng các mô hình mạng CNN để dự đoán các loại bệnh từ hình ảnh X quang ngực đã được tiền xử lý. Các mô hình mạng mà chúng tôi sử dụng bao gồm Dense121, VGG19, EfficientNetV2 và ConvNeXt. Các mô hình này đã được huấn luyện trên dữ liệu lớn và có khả năng học được các đặc trưng phức tạp từ hình ảnh.

Qua quá trình thử nghiệm và đánh giá, chúng tôi đã quan sát thấy hiệu suất được cải thiện rõ rệt trong việc dự đoán bệnh khi sử dụng các giải thuật tiền xử lý. Điều này đưa ra khẳng định rằng việc kết hợp các phương pháp tiền xử lý giúp nâng cao khả năng phân loại bệnh từ hình ảnh X quang ngực.

Nghiên cứu này có ý nghĩa quan trọng trong việc cung cấp cơ sở để phát triển các ứng dụng hỗ trợ chuẩn đoán và phân loại bệnh dựa trên hình ảnh X quang ngực. Việc sử dụng trí tuệ nhân tạo và mô hình học sâu có thể giúp tăng tốc quá trình chuẩn đoán và giảm thiểu sai sót của con người. Tuy nhiên, cần tiếp tục nghiên cứu và cải tiến để đảm bảo tính chính xác và độ tin cậy của hệ thống. Trong tương lai, chúng tôi đề xuất nghiên cứu thêm về sự kết hợp của các phương pháp tiền xử lý khác, cải thiện hiệu suất của các mô hình học sâu và mở rộng phạm vi ứng dụng đến các bệnh khác trong hình ảnh X quang ngực.

Tài liệu

1. P. Lei, Z. Huang, G. Liu, et al., “Clinical and computed tomographic (CT) images characteristics in the patients with COVID-19 infection: What should radiologists need to know,” *Journal of X-ray Science and Technology*, DOI: 10.3233/XST-200670 (2020).
2. A. Narin, C. Kaya, and Z. Pamuk, “Automatic detection of coronavirus disease (covid-19) using xray images and deep convolutional neural networks,” *arXiv preprint arXiv:2003.10849* (2020).
3. Ju-Youn Park, Yewon Hwang, Dukyoung Lee, and Jong-Hwan Kim. Marsnet: multi-label classification network for images of various sizes. *IEEE Access*, 8:21832–21846, 2020.
4. Ivo M Baltruschat, Hannes Nickisch, Michael Grass, Tobias Knopp, and Axel Saalbach. Comparison of deep learning approaches for multi-label chest x-ray classification. *Scientific reports*, 9(1):1–10, 2019.
5. Francesco Piccialli, Vittorio Di Somma, Fabio Giampaolo, Salvatore Cuomo, and Giancarlo Fortino. A survey on deep learning in medicine: Why, how and when? *Information Fusion*, 66:111–137, 2021.
6. S. Pan, and Q. Yang, “A survey on transfer learning,” *IEEE Transactions on Knowledge and Data Engineering*, 22 (2009), 1345-1359.

7. Xiaosong Wang, Yifan Peng, Le Lu, Zhiyong Lu, Mohammadhadi Bagheri, and Ronald M Summers. Chestx-ray: Hospital-scale chest x-ray database and benchmarks on weakly supervised classification and localization of common thorax diseases. *Deep Learning and Convolutional Neural Networks for Medical Imaging and Clinical Informatics*, page 369, 2019.
8. Jeremy Irvin, Pranav Rajpurkar, Michael Ko, Yifan Yu, Silvana Ciurea-Ilcus, Chris Chute, Henrik Marklund, Behzad Haghgoo, Robyn Ball, Katie Shpanskaya, et al. Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison. In *Proceedings of the AAAI conference on artificial intelligence*, volume 33, pages 590–597, 2019.